random3 Step 4~7+ 상세 대시보드 통합 문서

exact slim + strong context + SMILES 입력과 **random sample 3-fold** 기준으로 만든 각 단계 상세 대시보드를, 요약 없이 한 문서 안에서 그대로 이어서 볼 수 있게 정리한 페이지입니다.

← 메인 대시보드로 돌아가기

Step 4 / Step 5 모델 및 앙상블 상세
Step 6 METABRIC 외부 검증 상세
Step 7 ADMET / post-ADMET 상세
Step 7+ KG/API 근거 수집 상세

이번 버전은 요약 통합본이 아닙니다. Step 4/5, Step 6, Step 7, Step 7+ 각 상세 페이지의 카드, 표, 설명 블록을 그대로 이어서 보도록 만든 상세 통합본입니다. 그래서 각 단계에서 이미 만들어둔 세부 항목들을 따로 오가며 볼 필요 없이, 한 페이지에서 아래로 스크롤하면서 전체 흐름을 따라갈 수 있습니다.

STEP45

Step 4 / Step 5 모델 및 앙상블 상세

단일 모델 비교, 입력 구성, random sample 3-fold 해석, 앙상블 성능과 diversity까지 포함한 상세 대시보드입니다.

이 구간으로 이동

STEP6

Step 6 METABRIC 외부 검증 상세

타깃 발현, BRCA pathway 관련성, survival significance, validated top15까지 포함한 외부 검증 대시보드입니다.

이 구간으로 이동

STEP7

Step 7 ADMET / post-ADMET 상세

raw ADMET와 팀원 레포 형식의 임상 분류, ADMET 커버리지, 최종 15개 후보 표까지 포함합니다.

이 구간으로 이동

STEP7PLUS

Step 7+ KG/API 근거 수집 상세

ClinicalTrials, PubMed, FAERS, target/pathway 요약과 최종 후보별 설명 가능 근거를 정리한 상세 대시보드입니다.

이 구간으로 이동

STEP45

Step 4 / Step 5 모델 및 앙상블 상세

단일 모델 비교, 입력 구성, random sample 3-fold 해석, 앙상블 성능과 diversity까지 포함한 상세 대시보드입니다.

단독 페이지 열기

exact slim + strong context + SMILES - random sample 3-fold 상세 결과

← 파이프라인 대시보드로 돌아가기

Step 4 모델 | Step 5 앙상블 | Step 6 METABRIC | Step 7 ADMET | Step 7+ KG/API

실험 트랙 요약: `exact slim + strong context + SMILES` 입력을 기준으로, `random sample 3-fold KFold (seed=42)`에서 ML/DL 성능을 정리한 페이지입니다. 같은 약물이 train/valid에 동시에 들어갈 수 있는 분할이므로, **GroupCV보다 훨씬 낙관적으로 나오는 수치**라는 점을 같이 봐야 합니다.

입력셋: **exact slim + strong context + SMILES** 분할: **random sample 3-fold** seed: **42**

rows: **6,366** ML feature dim: **5,625** DL numeric dim: **5,529** strong context: **5 cols**

SMILES vocab: **38**

핵심 요약 완료

random sample 기준 최고 ML, 최고 DL, 전체 최고 수치를 먼저 요약했습니다.

CatBoost Best ML	**0.8706** Best ML Spearman	**TabNet** Best DL
0.8615 Best DL Spearman	**CatBoost** Best Overall	**1.1083** Best Overall RMSE

입력 구성과 해석 포인트

이번 random track이 어떤 입력을 쓰는지와, 왜 GroupCV보다 성능이 높게 나오는지를 같이 적어뒀습니다.

입력 구성

- exact slim numeric: 5,529 dim
- ML: 5,529 numeric + 32 strong context one-hot + 64 SMILES SVD = 5,625 dim
- DL: 5,529 numeric + strong context 5개 + SMILES branch
- strong context: TCGA_DESC, PATHWAY_NAME_NORMALIZED, classification, drug_bridge_strength, stage3_resolution_status

해석 메모

random sample split은 같은 약물이 train/valid 양쪽에 등장할 수 있어서, unseen-drug generalization을 보는 GroupCV보다 점수가 훨씬 높게 나옵니다. 그래서 이 페이지는 **ceiling / interpolation 성능 확인용**으로 해석하는 게 가장 적절합니다.

ML 모델 (6개) 완료

STEP6

Step 6 METABRIC 외부 검증 상세

타깃 발현, BRCA pathway 관련성, survival significance, validated top15까지 포함한 외부 검증 대시보드입니다.

단독 페이지 열기

exact slim + strong context + SMILES - random sample 3-fold METABRIC 외부 검증

← random3 상세 페이지로 돌아가기

Step 4 모델 | Step 5 앙상블 | **Step 6 METABRIC** | Step 7 ADMET | Step 7+ KG/API

검증 요약 완료

random3 weighted ensemble top30을 기준으로 METABRIC BRCA 외부 검증을 다시 계산한 결과입니다.

29/30 BRCA 발현 타겟	**23/30** BRCA 관련 경로	**28/30** 생존 유의
80.0% P@15 기존 BRCA 약물 정밀도	**0.821** RSF C-index	**0.94** GraphSAGE P@20

방법 A: 타겟 유전자 발현 검증

METABRIC BRCA 발현 데이터 대비 약물 타겟/경로가 실제로 잡히는지 확인했습니다.

#	약물	타겟	경로	발현%	Rank%	BRCA 경로
1	Bortezomib	Proteasome	Protein stability and degradation	YES	50.0	YES
2	Romidepsin	HDAC1, HDAC2, HDAC3, HDAC8	Chromatin histone acetylation	79%	87.9	YES
3	Sepantronium bromide	BIRC5	Apoptosis regulation	43%	53.4	YES
4	Docetaxel	Microtubule stabiliser	Mitosis	YES	50.0	YES
5	Dactinomycin	RNA polymerase	Other	YES	50.0	-
6	Paclitaxel	Microtubule stabiliser	Mitosis	YES	50.0	YES
7	Vinorelbine	Microtubule destabiliser	Mitosis	YES	50.0	YES
8	Vinblastine	Microtubule destabiliser	Mitosis	YES	50.0	YES
9	Staurosporine	Broad spectrum kinase inhibitor	RTK signaling	YES	50.0	-

10	SN-38	TOP1	DNA replication	45%	47.8	YES
11	Rapamycin	MTORC1	PI3K/MTOR signaling	YES	50.0	YES
12	Dinaciclib	CDK1, CDK2, CDK5, CDK9	Cell cycle	99%	74.8	YES
13	Daporinad	NAMPT	Metabolism	81%	59.7	-
14	Luminespib	HSP90	Protein stability and	YES	50.0	YES

STEP7

Step 7 ADMET / post-ADMET 상세

raw ADMET와 팀원 레포 형식의 임상 분류, ADMET 커버리지, 최종 15개 후보 표까지 포함합니다.

단독 페이지 열기

exact slim + strong context + SMILES - random sample 3-fold Step 7 ADMET 게이트

← random3 상세 페이지로 돌아가기

Step 4 모델 | Step 5 앙상블 | Step 6 METABRIC | Step 7 ADMET | Step 7+ KG/API

random3 post-ADMET summary 적용: 이번 route는 **top15가 이미 고유 약물**로 구성되어 있어 별도 중복 제거는 없었고, raw ADMET 분류(Approved/Candidate/Caution) 위에 **유방암 현재 사용 / 적응증 확장·연구 중 / 유방암 미사용** 임상 분류를 추가해 팀원 레포의 제출 형식에 맞게 정리했습니다. Top 5는 **Romidepsin, Sepantronium bromide, Staurosporine, SN-38, Docetaxel** 입니다.

ADMET 안전성 평가 및 유방암 적응증 분류 요약

5 유방암 현재 사용 (FDA 승인)	**6** 유방암 적응증 확장/연구 중	**4** 유방암 미사용 (신약 후보물질)
22 ADMET 분석 항목	**15** 고유 약물 후보	

유방암 임상 적응증 분류 기준

DrugBank · ClinicalTrials.gov · 팀원 레포 Step 7 해석 규칙 기반

분류	정의	약물 수
유방암 현재 사용	FDA 유방암 적응증 승인 또는 NCCN 가이드라인 포함 표준요법	5
적응증 확장/연구 중	유방암 대상 임상시험 진행 중이거나 유도체가 유방암 승인됨	6
유방암 미사용	유방암 적응증 없음, 신약 후보물질 또는 재창출 대상	4

ADMET 분석 커버리지 (22개 항목)

TDC ADMET benchmark | random3 Top15 후보 기준 | assay별 실제 매칭 수

범주	분석 항목	유형	매칭
Absorption	Caco-2 Permeability	회귀	4/15
Absorption	HIA (Human Intestinal Absorption)	이진	0/15
Absorption	P-gp Inhibitor	이진	2/15
Absorption	Oral Bioavailability (F>20%)	이진	2/15

Distribution	BBB Penetration	이진	5/15
Distribution	Plasma Protein Binding Rate	회귀	3/15
Distribution	Volume of Distribution	회귀	9/15
Metabolism	CYP2C9 Inhibitor	이진	4/15
Metabolism	CYP2D6 Inhibitor	이진	4/15
Metabolism	CYP3A4 Inhibitor	이진	3/15
Metabolism	CYP2C9 Substrate	이진	6/15

STEP7PLUS

Step 7+ KG/API 근거 수집 상세

ClinicalTrials, PubMed, FAERS, target/pathway 요약과 최종 후보별 설명 가능 근거를 정리한 상세 대시보드입니다.

단독 페이지 열기

random3 Step 7+ KG/API 검증 - 최종 후보 근거 요약

← random3 상세 페이지로 돌아가기

Step 4 모델 | Step 5 앙상블 | Step 6 METABRIC | Step 7 ADMET | Step 7+ KG/API

random3 최종 라우트 요약

random3 weighted ensemble (CatBoost + XGBoost + LightGBM + TabNet + ResidualMLP + WideDeep) 조합과 **exact slim + strong context + SMILES** 입력을 사용해 random sample 3-fold 기준 Step 6 METABRIC, Step 7 ADMET, Step 7+ KG/API 근거 수집까지 팀원 레포 흐름으로 정리했습니다.

Step 6: METABRIC | Step 7: ADMET Gate | Step 7+: KG/API Evidence

핵심 성능 및 최종 분류

random3 weighted ensemble 성능과 Step 6/7 최종 후보 분포를 함께 요약했습니다.

0.872 Ensemble Spearman	**1.102** Ensemble RMSE	**0.828** Ensemble MAE
8 Approved	**6** Candidate	**1** Caution
22 ADMET Assays	**15** KG/API Drug Count	

추천 요약

Top 5와 category별 shortlist를 빠르게 확인할 수 있게 묶었습니다.

Top 5 Final Candidates

Romidepsin, Sepantronium bromide, Staurosporine, SN-38, Docetaxel

Approved / Candidate / Caution

Approved: Romidepsin, Docetaxel, Bortezomib, Dactinomycin, Vinorelbine, Paclitaxel, Vinblastine, Rapamycin

Candidate: Sepantronium bromide, Staurosporine, SN-38, Dinaciclib, Camptothecin, Luminespib

Caution: Epirubicin

iframe 높이는 문서 로드 후 자동으로 맞춰집니다. 브라우저 폭이 바뀌면 높이도 다시 계산되도록 처리했습니다.

유방암 관련 약물 재창출 파이프라인 구축 프로젝트 이해 문서

프로젝트 기획부터 데이터, 모델, 검증, 최신 결과까지를 한 번에 파악할 수 있도록 정리한 설명 문서입니다.

유방암 관련 약물 재창출 파이프라인 구축 프로젝트 이해 문서

작성일: 2026-04-15 대상: 프로젝트를 처음 보는 팀원, 발표 준비자, 문서화 담당자 기준 저장소: skkuaws0215/20260408_pre_project_biso_myprotocol

---

1. 이 프로젝트를 한 문장으로 설명하면

이 프로젝트는 **유방암(BRCA)에서 기존 약물을 다시 쓸 수 있는 후보를 찾기 위해**, 환자 데이터, 세포주 약물 반응 데이터, 약물 구조/타깃 정보, 전사체 변화, 안전성 평가 데이터를 하나의 파이프라인으로 연결한 **약물 재창출(drug repurposing) 프로젝트**입니다.

조금 더 쉽게 말하면:

- 세포주에서 어떤 약이 잘 듣는지 학습하고
- 그 결과를 환자 데이터와 외부 검증 코호트에 비춰보고
- 마지막에는 ADMET와 지식그래프(KG)로 “실제로 검토할 만한 약인지”까지 확인하는 구조입니다.

---

2. 왜 이 프로젝트를 했는가

이 프로젝트가 풀고 싶은 질문은 단순합니다.

> “유방암에서 지금 안 쓰거나 덜 쓰는 약 중에서, 실제로 다시 검토할 가치가 있는 약을 찾을 수 있을까?”

하지만 실제로는 이 질문이 어렵습니다. 이유는 다음과 같습니다.

- 한 종류의 데이터만으로는 답을 내리기 어렵습니다.
- 세포주에서 잘 듣는 약이 환자에서도 의미가 있다는 보장이 없습니다.
- 약효가 보여도 독성이나 개발 가능성에서 탈락할 수 있습니다.
- 약물 이름, 구조식, 타깃 정보가 여러 데이터셋마다 다르게 표기되어 있어 먼저 연결 작업이 필요합니다.

그래서 이 프로젝트는 처음부터 “모델 정확도만 올리는 일”이 아니라, **데이터를 연결하고, 검증 단계를 여러 번 통과시키며, 최종 후보를 좁혀가는 실무형 파이프라인**으로 설계되었습니다.

2.1 팀 역할 분담

이 프로젝트는 역할을 분담해 병렬적으로 진행했습니다. 실제 작업에서는 일부 영역이 서로 맞물리지만, 문서 기준 책임 범위는 아래와 같습니다.

이름	역할	주요 담당
최현석 (팀장)	프로젝트 관리(PM)	프로젝트 전체 관리, 모델 고도화
소병임 (팀원)	프로젝트 기획	프로젝트 기획, 파이프라인 설계 및 구현
홍주영 (팀원)	데이터 담당	데이터 수집, 데이터 전처리 및 Feature Engineering
조창현 (팀원)	프론트엔드 및 문서 조사	프론트엔드 구축, 근거 문서 탐색

즉 이 프로젝트는 **기획-데이터-모델-프론트/근거 정리**가 분리된 협업 구조 위에서 진행되었고, 현재 문서의 sample 3-fold 결과도 그 역할 분담의 결과물로 이해하면 됩니다.

---

3. 전체 파이프라인을 큰 그림으로 보면

프로젝트 전체 흐름은 아래처럼 이해하면 가장 쉽습니다.

```
전처리 완료 데이터 확보
  -> feature engineering (세포주-약물 pair 문제로 변환)
  -> 모델 학습 및 다단계 평가
  -> 앙상블 및 후보 재정렬
  -> 외부 검증(METABRIC)
  -> ADMET 안전성 필터
  -> 지식그래프/KG/API 기반 근거 수집
  -> 최종 후보 해석 및 대시보드 제공
```

즉 이 프로젝트는 한 번 모델을 돌리고 끝나는 구조가 아니라:

1. **학습용 pair 데이터 만들기**
2. **여러 모델을 비교하기**
3. **더 어려운 split으로 일반화 확인하기**
4. **환자 코호트로 외부 검증하기**
5. **ADMET로 위험 후보를 걸러내기**
6. **KG/API/PubMed로 근거를 보강하기**

까지 이어지는 구조입니다.

---

4. 어떤 데이터가 어디에 쓰였는가

이 프로젝트를 이해할 때 가장 중요한 점은, **데이터마다 역할이 다르다**는 것입니다.

4.1 환자/질병 맥락 데이터

TCGA-BRCA

- 유방암 환자 코호트의 기준 데이터입니다.
- RNA, clinical, biospecimen inventory를 통해 질병 맥락을 정의합니다.
- feature engineering에서 어떤 유전자/경로를 볼 것인지의 기준축이 됩니다.

METABRIC

- 외부 검증 코호트입니다.
- GDSC에서 학습한 모델이 실제 환자 맥락에서도 의미가 있는지 확인하는 데 사용됩니다.

- 발현, 생존, 정밀도 평가에 활용됩니다.

4.2 실제 학습 라벨 데이터

GDSC2 BRCA

- 이 프로젝트의 핵심 학습 라벨 데이터입니다.
- 세포주 × 약물 조합마다 `LN(IC50)`, `AUC`, 민감도 정보를 제공합니다.
- 모델 입장에서는 "정답 y"에 해당합니다.

`DATA_PROVENANCE.md` 기준 핵심 수치:

- 13,388 rows
- 52개 cell lines
- 295개 drugs

4.3 세포주 특성 데이터

DepMap CRISPR

- 세포주별 gene dependency 정보를 제공합니다.
- "이 세포주가 어떤 유전자 축에 의존하는가"를 sample-level feature로 변환합니다.
- 같은 BRCA여도 세포주 biology가 다르기 때문에, 이 차이를 설명하는 데 중요합니다.

4.4 약물 perturbation 데이터

LINCS MCF7

- 약물 처리 후 전사체가 어떻게 바뀌는지를 보여주는 perturbation signature입니다.
- 약물이 세포 상태를 어떤 방향으로 움직이는지 반영하기 때문에, 단순 구조 유사성보다 더 풍부한 pair-level feature를 만듭니다.

`DATA_PROVENANCE.md` 기준:

- 63,367 MCF7 signatures
- 12,328 gene columns

4.5 약물 표준화/타깃 연결 데이터

DrugBank / ChEMBL

- 약물 이름, canonical identifier, SMILES, 타깃, 기전을 정리하는 표준 지식 베이스입니다.

- 여러 데이터셋에 흩어진 약물 정보를 같은 약물로 연결하는 데 핵심입니다.
- 후반부 해석과 KG 연결에도 중요합니다.

4.6 후속 검증/설명 데이터

ADMET / OpenTargets / STRING

- 모델 학습의 주 라벨은 아니지만, 최종 후보를 안전성/생물학적 타당성 기준으로 재정렬하는 데 쓰입니다.
- 특히 ADMET은 “성능이 높아도 위험한 약”을 걸러내는 마지막 안전장치 역할을 합니다.

4.7 요약

한 줄로 요약하면:

- `GDSC2 BRCA` 는 정답(y)
- `DepMap` 과 `LINCS` 는 feature(X) 보강
- `TCGA-BRCA` 와 `METABRIC` 은 질병 맥락 및 외부 검증
- `DrugBank/ChEMBL` 은 약물 표준화
- `ADMET/OpenTargets/STRING` 은 최종 후보 재검증

---

7. 사용모델

이 문서에서는 이제부터 **exact slim + strong context + SMILES** 입력과 **random sample 3-fold (seed=42)** 결과만을 기준으로 모델과 지표를 해석합니다.

현재 sample 3-fold 기준 Step 4에서 실제로 비교한 모델은 다음과 같습니다.

7.1 ML 모델

- CatBoost
- XGBoost
- LightGBM
- LightGBM_DART
- ExtraTrees
- RandomForest

7.2 DL 모델

- TabNet
- ResidualMLP
- WideDeep
- FlatMLP
- CrossAttention
- FTTransformer

7.3 Step 5 앙상블

sample 3-fold에서 최종 비교한 weighted ensemble은 아래 6개 base model을 사용합니다.

- CatBoost
- XGBoost
- LightGBM
- TabNet
- ResidualMLP
- WideDeep

즉 현재 문서의 기준 실험은 **sample 3-fold 위에서 ML/DL 단일모델을 비교하고, 그 위에 혼합 앙상블을 얹어 Step 6~7+까지 내리는 구조**입니다.

---

8. 모델링 결과는 어떻게 해석해야 하는가

현재 문서에서 봐야 할 모델 성능은 전부 **sample 3-fold** 기준입니다. 즉 같은 약물이 train/valid 양쪽에 등장할 수 있는 더 쉬운 split에서의 ceiling과 interpolation 성능을 보는 지표라고 이해하면 됩니다.

8.1 Step 4 단일모델 요약

- **최고 ML**: CatBoost — Spearman `0.8706`, RMSE `1.1083`, MAE `0.8327`, Pearson `0.9127`, R^2 `0.8322`
- **차상위 ML**: XGBoost — Spearman `0.8647`, RMSE `1.1347`
- **차상위 ML**: LightGBM — Spearman `0.8637`, RMSE `1.1358`

- **최고 DL**: TabNet — Spearman `0.8613`, RMSE `1.1560`, MAE `0.8768`, Pearson `0.9055`, R^2 `0.8175`
- **차상위 DL**: ResidualMLP — Spearman `0.8599`, RMSE `1.1620`
- **차상위 DL**: WideDeep — Spearman `0.8572`, RMSE `1.1639`

즉 sample 3-fold 기준으로 보면 **ML에서는 CatBoost**, **DL에서는 TabNet / ResidualMLP / WideDeep** 축이 가장 강합니다.

8.2 Step 5 앙상블 요약

- **weighted ensemble**: Spearman `0.8720`, RMSE `1.1016`, MAE `0.8281`, Pearson `0.9137`, R^2 `0.8343`
- **구성**: CatBoost + XGBoost + LightGBM + TabNet + ResidualMLP + WideDeep

여기서 핵심은 단순합니다.

> sample 3-fold에서는 단일모델 최고도 강하지만, ML과 DL을 섞은 weighted ensemble이 가장 좋은 ceiling을 보여준다.

다만 이 값은 unseen-drug 일반화 성능이 아니라 **더 쉬운 random sample split에서의 상한선**이라는 점을 항상 같이 기억해야 합니다.

---

9. 외부 검증은 어떻게 했는가

Step 6의 질문은 sample 3-fold 기준으로도 동일합니다.

> "sample 3-fold에서 잘 나온 상위 약물 랭킹이 METABRIC BRCA 환자 코호트에서도 생물학적으로 타당한가?"

검증은 세 축으로 진행했습니다.

9.1 Method A: 타깃 발현 / 경로 정합성

- 약물 타깃이 METABRIC BRCA 발현 데이터에서 실제로 관찰되는지 확인

- gene-level target이면 발현 퍼센트와 rank percentile 계산
- mechanism/pathway-level target이면 `YES` 로 표기해 유효 타깃으로 인정

9.2 Method B: Survival analysis

- 타깃 발현 기준으로 환자를 나눠 생존 차이가 유의한지 확인
- RSF C-index와 AUROC를 함께 참고

9.3 Method C: 기존 BRCA 약물 정밀도

- Top 후보 안에 BRCA 관련 약물이 얼마나 들어오는지 P@K로 평가
- GraphSAGE P@20을 보조 참고값으로 사용

현재 sample 3-fold route의 Step 6 결과는 다음과 같습니다.

- **Target expressed**: `29 / 30`
- **BRCA pathway relevant**: `23 / 30`
- **Survival significant**: `28 / 30`
- **P@15**: `80.0%`
- **RSF C-index**: `0.8209`
- **GraphSAGE P@20**: `0.94`

대표 validated 상위 후보는 **Bortezomib**, **Romidepsin**, **Sepantronium bromide**, **Docetaxel**, **Dactinomycin** 입니다.

즉 Step 6은 sample 3-fold 성능이 단순한 interpolation 숫자에 그치지 않고, **환자 코호트 기준 생물학적 타당성으로도 어느 정도 지지를 받는지 확인하는 관문**이라고 보면 됩니다.

---

10. ADMET 단계에서는 무엇을 했는가

Step 7은 sample 3-fold 앙상블이 올린 상위 후보를 **실제 shortlist**로 바꾸는 마지막 안전성 게이트입니다. 이 문서에서는 sample 3-fold route의 결과만 기준으로 봅니다.

10.1 Raw ADMET 결과

- **Final candidates**: `15`
- **Approved**: `8`

- **Candidate**: `6`
- **Caution**: `1`
- **Top 1**: `Romidepsin`

Top 5 final candidate는 다음과 같습니다.

- Romidepsin
- Sepantronium bromide
- Staurosporine
- SN-38
- Docetaxel

여기서 **Caution**은 사실상 **Epirubicin** 1개이며, `Ames` 와 `DILI` 플래그가 동시에 잡힙니다.

10.2 Post-ADMET 임상 분류

팀원 레포 형식에 맞춰 같은 15개 후보를 임상적 의미로 다시 분류하면 아래와 같습니다.

- **유방암 현재 사용**: `5`
- **적응증 확장 / 연구 중**: `6`
- **유방암 미사용**: `4`
- **ADMET 분석 항목**: `22`

즉 Step 7의 핵심 메시지는 이렇습니다.

> sample 3-fold에서 모델 점수가 높은 약물이라고 바로 최종 후보가 되는 것이 아니라, 외부 검증과 ADMET 게이트를 통과한 약물만 shortlist에 남는다.

---

11. KG/API 단계는 왜 필요한가

Step 7+ KG/API 단계는 sample 3-fold 기준 Top 15 최종 후보에 대해 **설명 가능한 근거를 붙이는 단계**입니다. 현재 연결한 API 층은 아래와 같습니다.

- ClinicalTrials.gov
- PubMed E-utilities

- openFDA FAERS
- drug / target / pathway seed catalog

현재 sample 3-fold route에서는 **최종 후보 15개 전부에 대해 KG/API 요약 결과를 생성**했습니다. 수집 구조상 약물마다 실제 응답 수는 다를 수 있지만, 각 후보에 대해 아래 정보 조합을 확인할 수 있습니다.

- basic info
- side effects
- trials
- targets
- pathways
- pubmed general
- pubmed breast cancer

대표적으로 KG/API 요약 상위권에 다시 나타나는 약물은 **Romidepsin**, **Sepantronium bromide**, **Staurosporine**입니다.

> 즉 Step 7+는 "최종 후보 15개 각각에 대해 임상시험, 부작용, 타깃/경로, 문헌 근거를 붙여서 사람이 설명 가능한 후보로 바꾸는 단계"라고 이해하면 됩니다.

이제 sample 3-fold 경로도 **Step 4 → Step 5 → Step 6 → Step 7 → Step 7+** 흐름을 끝까지 따라갈 수 있는 상태가 됐습니다.

---

12. 현재 시점에서 이 프로젝트는 어디까지 왔는가

2026-04-16 기준으로, 이 문서는 **sample 3-fold route 하나를 기준으로 Step 1~7+까지 재현한 상태**를 정리합니다.

> **exact slim + strong context + SMILES 입력 위에서 random sample 3-fold 모델링, 앙상블, METABRIC 외부 검증, ADMET, KG/API 근거 수집까지 한 흐름으로 연결한 상태**라고 보면

> 됩니다.

좀 더 구체적으로 보면:

- **Step 4**: CatBoost(best ML) / TabNet(best DL) 중심으로 single-model ceiling 확인
- **Step 5**: 6-model weighted ensemble으로 Spearman `0.8720`, RMSE `1.1016` 확보
- **Step 6**: METABRIC에서 `29/30`, `23/30`, `28/30`, `P@15 80.0%` 수준으로 외부 검증 완료
- **Step 7**: raw ADMET `8 / 6 / 1`, post-ADMET 임상 분류 `5 / 6 / 4`로 정리 완료
- **Step 7+**: KG/API 근거 수집 및 후보별 요약표 생성 완료

이미 안정화된 것

- sample 3-fold용 상세 페이지 묶음 (Step 4/5, Step 6, Step 7, Step 7+)
- METABRIC 외부 검증 수치와 validated top15
- ADMET + post-ADMET 임상 분류
- KG/API 기반 문헌/임상/부작용 요약

아직 열려 있는 질문

- 이 ceiling이 더 어려운 split에서도 유지되는가
- scaffold 수준으로 약물 구성이 달라져도 같은 후보가 얼마나 남는가
- sample 3-fold에서 강한 후보가 truly unseen-drug 환경에서도 강한가

즉 현재 문서의 관점은 **sample 3-fold 기준 완성된 end-to-end 경로를 정리하고, 그 의미와 한계를 같이 기록하는 상태**입니다.

---

13. 이 프로젝트를 처음 읽는 사람이 어디부터 보면 좋은가

지금 문서를 읽을 때는 **sample 3-fold 경로** 하나만 따라가면 됩니다. 가장 효율적인 순서는 아래와 같습니다.

1순위: sample 3-fold 상세 페이지부터 보기

- 현재 재현 대시보드
- sample 3-fold Step 4/5 상세

- sample 3-fold Step 6 METABRIC 상세
- sample 3-fold Step 7 ADMET 상세
- sample 3-fold Step 7+ KG/API 상세

2순위: 팀원 원본 구조 이해하기

- DATA_PROVENANCE.md
- protocol_guide.md
- 원본 dashboard.html

즉 지금은 여러 경로를 동시에 비교하기보다, **sample 3-fold 대시보드에서 Step 4 → 5 → 6 → 7 → 7+**를 먼저 따라가면서 전체 파이프라인을 잡는 것이 가장 효율적입니다.

---

14. 발표 자료를 만들 때 잡아야 할 메시지

이 문서를 바탕으로 발표를 만든다면, 메시지는 아래 4개로 압축하는 것이 좋습니다.

메시지 1

이 프로젝트는 단순한 모델 비교가 아니라, **데이터 정합성 → feature engineering → sample 3-fold 모델링 → 외부 검증 → 안전성 필터 → KG/API 근거 수집**까지 연결한 실전형 파이프라인이다.

메시지 2

sample 3-fold 기준으로는 **CatBoost가 최고 ML**, **TabNet이 최고 DL**, 그리고 **ML+DL 혼합 weighted ensemble이 전체 최고 성능**을 보였다.

메시지 3

좋은 모델 점수만으로는 충분하지 않고, **METABRIC 외부 검증과 ADMET를 통과해야 실제 후보로 남는다.**

메시지 4

최종 후보는 마지막에 **KG/API, PubMed, ClinicalTrials, FAERS**까지 붙여 사람이 설명 가능한 후보로 바뀐다.

---

15. 마지막 요약

이 문서는 지금 세 가지를 동시에 보여줍니다.

1. **데이터 연결**

- 여러 생물학적 데이터셋을 하나의 sample-drug 예측 문제로 바꾸는 과정

1. **sample 3-fold 모델링**

- ML, DL, 혼합 앙상블을 비교해 ceiling을 확인하는 과정

1. **후보 검증과 해석**

- METABRIC, ADMET, KG/API, 문헌까지 연결해 최종 후보를 좁히는 과정

그래서 이 문서를 읽을 때는 “모델 정확도”만 볼 게 아니라,

- sample 3-fold에서 어떤 모델이 제일 강했는지
- 그 후보가 METABRIC에서도 지지되는지
- ADMET를 통과하는지
- 마지막에 어떤 문헌/임상/부작용 근거가 붙는지

를 한 흐름으로 같이 봐야 합니다.

이 문서를 한 문장으로 다시 정리하면:

> **biso_myprotocol은 유방암 약물 재창출을 위해 데이터 연결, sample 3-fold 모델링, 외부 검증, 안전성 평가, 설명 가능한 근거 수집을 하나의 파이프라인으로 묶은 실전형 프로젝트이며, 현재 이 문서는 그 흐름을 Step 1~7+까지 random sample 3-fold 기준으로 정리한 상태다.**