PROJECT PRESENTATION

유방암 관련 약물 재창출 파이프라인 구축

데이터 기반 신약 재창출 연구

유방암(BRCA)에서 기존 약물의 재적용 후보를 **end-to-end 파이프라인** 으로 도출

최현석 (PM)
프로젝트 관리 / 모델 고도화

소병임 (기획)
파이프라인 설계 및 구현

홍주영 (데이터)
데이터 수집 / 전처리 / Feature Eng.

조창현 (프론트/문서)
프론트엔드 구축 / 근거 문서 탐색

2026-04-16

프로젝트 배경과 목표

약물 재창출의 필요성과 파이프라인 구축의 핵심 도전과제

💡 왜 약물 재창출인가?

신약 개발 대비 비용과 시간을 줄이면서, 이미 임상/독성 정보가 축적된 물질을 활용해 **유방암 적응증 재검토** 가능성을 탐색하는 것이 목표입니다.

> **"유방암에서 현재 사용되지 않거나 덜 쓰이는 약 중, 실제로 다시 재검토할 가치가 있는 약물을 찾을 수 있을까?"**

⚠️ 파이프라인 구축의 주요 도전과제

- **데이터 연결성**: GDSC, DepMap, LINCS, TCGA, METABRIC, DrugBank/ChEMBL 연결
- **임상 번역 가능성**: 세포주 성능이 실제 환자 코호트(METABRIC)에서도 유지되는지 검증
- **후보 안전성**: ADMET 기반 독성·약동학 필터로 후보 현실성 확보
- **설명 가능성**: KG/API로 타깃, 문헌, 임상시험, 부작용 근거 매핑

전체 파이프라인 흐름 (7단계)

데이터 수집부터 KG/API 근거 수집까지의 end-to-end 프로세스

Step 1
수집 & 정합성
GDSC / DepMap / LINCS / TCGA-BRCA / DrugBank / ChEMBL

Step 2
Feature Eng.
sample-drug pair 생성
exact slim + context + SMILES

Step 3
모델 학습
ML 6개 + DL 6개
random sample 3-fold

Step 4
앙상블
CatBoost + XGBoost + LightGBM + TabNet + ResidualMLP + WideDeep

Step 5
외부 검증
METABRIC 타깃 발현 / survival / precision

Step 6
안전성 평가
ADMET raw gate + post-ADMET 임상 분류

Step 7
근거 수집
KG/API (Trials, PubMed, FAERS, target/pathway)

현재 발표 수치는 **exact slim + strong context + SMILES** 입력과 **random sample 3-fold** 기준으로 정리했습니다. 이 경로는 ceiling/interpolation 성능을 보여주는 reference route입니다.

입력 데이터와 모델 입력 구성

정답(y), feature(X), 외부 검증, 안전성/설명 데이터의 역할 분리

13,388
GDSC2 BRCA 라벨 rows

52
Cell lines

295
Drugs

6,366
Sample 3-fold training rows

🧬 데이터 소스와 역할

- **GDSC2 BRCA**: 약물 반응 정답(y)
- **DepMap CRISPR**: 세포주 gene dependency
- **LINCS MCF7**: 약물 perturbation signature
- **DrugBank / ChEMBL**: SMILES, 타깃, pathway 표준화
- **METABRIC**: 외부 검증 코호트
- **ADMET / KG/API**: 안전성 및 설명 근거

📦 이번 실험의 최종 입력

- **exact slim numeric**: 5,529 dim
- **strong context**: 5개 컬럼 TCGA_DESC, PATHWAY_NAME_NORMALIZED, classification, drug_bridge_strength, stage3_resolution_status
- **SMILES**: 토큰 기반 branch + ML용 64-dim SVD
- **ML input dim**: 5,625

random sample 3-fold는 같은 약물이 train/valid 양쪽에 등장할 수 있어 GroupCV보다 높게 나오는 **상한선**

(reference ceiling)으로 해석해야 합니다.

Step 4. 단일 모델 비교

sample 3-fold 기준 최고 ML은 CatBoost, 최고 DL은 TabNet

0.8706
CatBoost Spearman

1.1083
CatBoost RMSE

0.8613
TabNet Spearman

1.1560
TabNet RMSE

Step 4~5 Spearman 비교

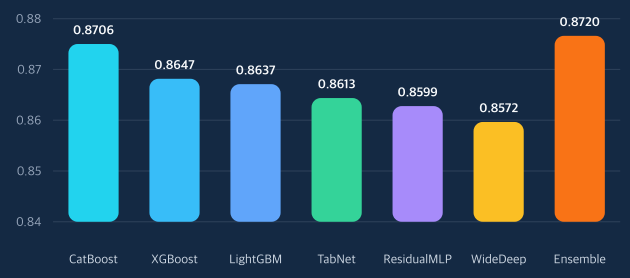

해석 포인트

- ML 상위권: **CatBoost, XGBoost, LightGBM**
- DL 상위권: **TabNet, ResidualMLP, WideDeep**
- 단일모델 기준에서는 ML이 조금 더 안정적이었고, DL은 근접한 후보군으로 경쟁했습니다.

발표에서는 “모델 family를 넓게 비교한 뒤, Step 5에서 ML+DL 혼합 앙상블로 ceiling을 조금 더 밀어 올렸다”는 흐름으로 설명하면 좋습니다.

Step 4~5 RMSE 비교

1.18
1.16
1.14
1.11
1.09
1.108
1.135
1.136
1.156
1.162
1.164
1.102
CatBoost
XGBoost
LightGBM
TabNet
ResidualMLP
WideDeep
Ensemble

Step 5. 혼합 앙상블

ML 3개 + DL 3개를 섞은 weighted ensemble이 전체 최고 성능

0.8720	1.1016	0.8281	0.9137
Weighted Spearman	Weighted RMSE	Weighted MAE	Weighted Pearson

Step 5 weighted ensemble 구성 비중

선택된 base model

CatBoost / XGBoost / LightGBM / TabNet / ResidualMLP / WideDeep

Diversity summary

- avg prediction Pearson: **0.9817**
- avg residual Pearson: **0.9158**
- avg mean abs gap: **0.3465**

residual correlation이 여전히 높아서 “완전히 다른 오류 패턴”보다는 평균화 이득이 중심이었습니다.

Step 6. METABRIC 외부 검증

sample 3-fold top30이 환자 코호트에서도 생물학적 타당성을 가지는지 검증

Target expressed 29/30
96.7% 타깃 발현 확인

BRCA pathway relevant 23/30
76.7% 경로 정합성

Survival significant 28/30
93.3% 생존 유의

P@15 / RSF / Graph 80.0%
RSF C-index 0.8209 · GraphSAGE P@20 0.94

Validated Top 5

#	Drug	Target	Combined
1	Bortezomib	Proteasome	12.79
2	Romidepsin	HDAC1/2/3/8	19.00
3	Sepantronium bromide	BIRC5	16.50
4	Docetaxel	Microtubule stabiliser	12.83
5	Dactinomycin	RNA polymerase	13.00

핵심 메시지

- 단순히 sample 3-fold에서 숫자가 높은 후보를 고른 것이 아니라,
- **METABRIC BRCA** 환자 코호트에서 타깃 발현과 생존, 기존 BRCA 약물 정밀도로 다시 검증했습니다.

대표적으로 **Bortezomib**, **Romidepsin**,

Sepantronium bromide, **Docetaxel**, **Dactinomycin**가 상위 validated 후보였습니다.

Step 7. ADMET 및 post-ADMET 분류

raw 안전성 게이트와 유방암 임상 분류를 함께 적용해 최종 15개 후보를 정리

유방암 현재 사용	5
적응증 확장/연구 중	6
유방암 미사용	4

8
Raw Approved

6
Raw Candidate

1
Raw Cau

Top 5 final candidate

Romidepsin · Sepantronium bromic
Staurosporine · SN-38 · Docetaxel

Caution: Epirubicin (Ames / DILI 플그)

팀원 레포 형식 기준으로는 **현재 사용 5 확장·연구 중 6 / 미사용 4**로 다시 정리습니다.

Top 5 최종 후보와 임상 분류

#	Drug	임상 분류	Combined Score
1	Romidepsin	적응증 확장/연구 중	19.0
2	Sepantronium bromide	유방암 미사용	16.5

#	Drug	임상 분류	Combined Score
3	Staurosporine	유방암 미사용	13.5
4	SN-38	적응증 확장/연구 중	13.0
5	Docetaxel	유방암 현재 사용	12.83

Step 7+. KG/API 근거 수집 및 최종 메시지

ClinicalTrials, PubMed, FAERS, target/pathway를 붙여 설명 가능한 최종 후보로 변환

15
KG/API Candidate Count

Romidepsin
Top Candidate

Trials
ClinicalTrials.gov

PubMed
문헌 근거

KG/API evidence top 5

Drug	Trials	PubMed	PubMed BRCA	Targets	Pathways
Romidepsin	1	1	0	4	1
Sepantronium bromide	0	1	0	0	0
Staurosporine	2	50	50	1	1
SN-38	1	1	0	1	1
Docetaxel	10	50	50	1	1

발표용 최종 메시지

1. 이 프로젝트는 데이터 연결 → 모델링 → 외부 검증 → 안전성 평가 → KG/API 근거 수집까지 이어지는 **end-to-end 유방암 약물 재창출 파이프라인**입니다.

2. sample 3-fold 기준 최고

단일 모델은 **CatBoost**, 최고 DL은 **TabNet**, 최고 전체 성능은 **혼합 weighted ensemble**이었습니다.

3. 최종적으로는 **Romidepsin**, **Sepantronium bromide**, **Staurosporine**, **SN-38**, **Docetaxel**이 강한 후보로 남았습니다.

4. 다만 이 경로는 **sample 3-fold ceiling**이므로, 실제 일반화 성능 논의에서는 GroupCV와 같이 읽어야 합니다.

참고 문서: 프로젝트 이해 문서, random3 Step 4~7+ 상세 통합 대시보드, Step 6/7/7+ 세부 결과 파일