PROJECT PRESENTATION

유방암 관련 약물 재창출 파이프라인 구축

데이터 기반 신약 재창출 연구

유방암(BRCA)에서 기존 약물의 재적용 후보를 **end-to-end 파이프라인** 으로 도출

최현석 (PM)
프로젝트 관리 / 모델 고도화

소병임 (기획)
파이프라인 설계 및 구현

홍주영 (데이터)
데이터 수집 / 전처리 / Feature Eng.

조창현 (프론트/문서)
프론트엔드 구축 / 근거 문서 탐색

2026-04-16

프로젝트 배경과 목표

약물 재창출의 필요성과 파이프라인 구축의 핵심 도전과제

💡 왜 약물 재창출인가?

신약 개발 대비 비용과 시간을 줄이면서, 이미 임상/독성 정보가 축적된 물질을 활용해 **유방암 적응증 재검토** 가능성을 탐색하는 것이 목표입니다.

> **"유방암에서 현재 사용되지 않거나 덜 쓰이는 약 중, 실제로 다시 재검토할 가치가 있는 약물을 찾을 수 있을까?"**

⚠️ 파이프라인 구축의 주요 도전과제

- **데이터 연결성**: GDSC, DepMap, LINCS, TCGA, METABRIC, DrugBank/ChEMBL 연결
- **임상 번역 가능성**: 세포주 성능이 실제 환자 코호트(METABRIC)에서도 유지되는지 검증
- **후보 안전성**: ADMET 기반 독성·약동학 필터로 후보 현실성 확보
- **설명 가능성**: KG/API로 타깃, 문헌, 임상시험, 부작용 근거 매핑

전체 파이프라인 흐름 (7단계)

데이터 수집부터 KG/API 근거 수집까지의 end-to-end 프로세스

Step 1
수집 & 정합성
GDSC / DepMap / LINCS / TCGA-BRCA / DrugBank / ChEMBL

Step 2
Feature Eng.
sample-drug pair 생성
exact slim + context + SMILES

Step 3
모델 학습
ML 6개 + DL 6개
random sample 3-fold

Step 4
앙상블
CatBoost + XGBoost + LightGBM + TabNet + ResidualMLP + WideDeep

Step 5
외부 검증
METABRIC 타깃 발현 / survival / precision

Step 6
안전성 평가
ADMET raw gate + post-ADMET 임상 분류

Step 7
근거 수집
KG/API (Trials, PubMed, FAERS, target/pathway)

현재 발표 수치는 **exact slim + strong context + SMILES** 입력과 **random sample 3-fold** 기준으로 정리했습니다. 이 경로는 ceiling/interpolation 성능을 보여주는 reference route입니다.

입력 데이터와 모델 입력 구성

정답(y), feature(X), 외부 검증, 안전성/설명 데이터의 역할 분리

13,388	52	295	6,366
GDSC2 BRCA 라벨 rows	Cell lines	Drugs	Sample 3-fold training rows

🧬 데이터 소스와 역할

- **GDSC2 BRCA**: 약물 반응 정답(y)
- **DepMap CRISPR**: 세포주 gene dependency
- **LINCS MCF7**: 약물 perturbation signature
- **DrugBank / ChEMBL**: SMILES, 타깃, pathway 표준화
- **METABRIC**: 외부 검증 코호트
- **ADMET / KG/API**: 안전성 및 설명 근거

📦 이번 실험의 최종 입력

- **exact slim numeric**: 5,529 dim
- **strong context**: 5개 컬럼
  TCGA_DESC, PATHWAY_NAME_NORMALIZED, classification, drug_bridge_strength, stage3_resolution_status
- **SMILES**: 토큰 기반 branch + ML용 64-dim SVD
- **ML input dim**: 5,625

random sample 3-fold는 같은 약물이 train/valid 양쪽에 등장할 수 있어 GroupCV보다 높게 나오는 **상한선(reference ceiling)**으로 해석해야 합니다.

Step 4. 단일 모델 비교

sample 3-fold 기준 최고 ML은 CatBoost, 최고 DL은 TabNet

0.8706	1.1083	0.8613	1.1560
CatBoost Spearman	CatBoost RMSE	TabNet Spearman	TabNet RMSE

Step 4~5 Spearman 비교

해석 포인트

- ML 상위권: **CatBoost, XGBoost, LightGBM**
- DL 상위권: **TabNet, ResidualMLP, WideDeep**
- 단일모델 기준에서는 ML이 조금 더 안정적이었고, DL은 근접한 후보군으로 경쟁했습니다.

발표에서는 "모델 family를 넓게 비교한 뒤, Step 5에서 ML+DL 혼합 앙상블로 ceiling을 조금 더 밀어 올렸다"는 흐름으로 설명하면 좋습니다.

Step 4~5 RMSE 비교